

# 지식표현과 추론

## 확률 그래프 모델과 지식 표현의 문제

이건명

충북대학교 소프트웨어학과

인공지능 : 튜링 테스트에서 딥러닝까지

# 학습 내용

---

- 확률 그래프 모델의 개념에 대해서 알아본다.
- 베이지안 망, 마르코프 랜덤 필드, 조건부 랜덤 필드, 로그-선형 모델의 형태에 대해서 알아본다.
- 심볼 그라운드링 문제와 프레임 문제에 대해서 알아본다.
- 상식의 표현에 대해서 알아본다.

# 1. 확률 그래프 모델

## ❖ 확률 그래프 모델(probabilistic graphical model)

- 확률 이론과 그래프 이론을 결합하여 **확률분포**(probability distribution)를 **표현**하고,  
관심있는 대상(**확률변수**)에 대한 **확률** 또는 **확률분포**를 **계산**할 수 있는 모델
- 확률분포를 이용한 지식표현을 하고 확률적 추론
- 베이지안 망
- 마르코프 랜덤 필드(마르코프 망)
- 조건부 랜덤 필드
- 로그-선형 모델

# 확률 그래프 모델

## ❖ 확률 그래프 모델(probabilistic graphical model)

### ▪ 예. 절도 경보 문제

- 절도가 발생하거나 지진이 발생하면 경보 발생
- 경보가 울리면 이웃이 전화

### • 불확실한 요소가 있어 확률로 표현

#### – 확률변수(random variable)

- » 경보 작동(**A**; alarm)
- » 절도 발생(**B**; burglary)
- » 지진 발생(**E**; earthquake)
- » 이웃 전화(**N**; neighbor call)



# 확률 그래프 모델

## ▪ 절도 경보 문제의 확률분포에 의한 지식표현

- 지진 발생(E), 절도 발생(B), 경보 생성(A), 이웃전화 (N)
- 결합확률 분포로 표현

$E$	$B$	$A$	$N$	확률
F	F	F	F	0.56133
F	F	F	T	0.06237
F	F	T	F	0.00126
F	F	T	T	0.00504
F	T	F	F	0.0243
F	T	F	T	0.0027
F	T	T	F	0.0486
F	T	T	T	0.1944
T	F	F	F	0.0189
T	F	F	T	0.0021
T	F	T	F	0.0098
T	F	T	T	0.0392
T	T	F	F	0.00027
T	T	F	T	0.00003
T	T	T	F	0.00594
T	T	T	T	0.02376



경보가 울릴 때 이웃이 전화할 확률은?

$$P(N = T | A = T) = ?$$

이웃이 전화했을 때 도둑이 들었을 확률은?

$$P(B = T | N = T) = ?$$

# 확률 그래프 모델

## ❖ 조건부 독립과 확률분포의 인수분해(factorization)

- 사건의 독립(independence)
  - $P(E, B) = P(E)P(B)$
- 조건부 독립(conditional independence) 성질 이용
  - $P(N, A|E) = P(N|E)P(A|E)$
- 확률분포의 인수분해
  - $P(A, B) = P(A|B)P(B)$
  - $P(A_1, A_2, A_3, A_4) = P(A_1|A_2, A_3, A_4)P(A_2|A_3, A_4)P(A_3|A_4)P(A_4)$

# 확률 그래프 모델

## ❖ 조건부 독립을 이용한 확률분포의 인수 분해

$$P(N, A, E, B) = P(N|A, E, B)P(A|E, B)P(E|B)P(B)$$

만족하는 조건부 독립 성질

$$P(N|A, E, B) = P(N|A)$$

$$P(E|B) = P(E)$$

$$= P(N|A)P(A|E, B)P(E)P(B)$$

A	N	
	F	T
F	0.9	0.1
T	0.2	0.8

E	B	A	
		F	T
F	F	0.99	0.01
F	T	0.1	0.9
T	F	0.3	0.7
T	T	0.01	0.99

E	
F	T
0.9	0.1

B	
F	T
0.7	0.3

E	B	A	N	확률
F	F	F	F	0.56133
F	F	F	T	0.06237
F	F	T	F	0.00126
F	F	T	T	0.00504
F	T	F	F	0.0243
F	T	F	T	0.0027
F	T	T	F	0.0486
F	T	T	T	0.1944
T	F	F	F	0.0189
T	F	F	T	0.0021
T	F	T	F	0.0098
T	F	T	T	0.0392
T	T	F	F	0.00027
T	T	F	T	0.00003
T	T	T	F	0.00594
T	T	T	T	0.02376

$$P(N = T, A = T, E = F, B = T)$$

$$= P(N = T|A = T)P(A = T|E = F, B = T)P(E = F)P(B = T)$$


$$= 0.8 \times 0.9 \times 0.9 \times 0.3$$

$$= 0.1944$$

## 2. 베이지안 망

### ❖ 베이지안 망(Bayesian network)

- 확률변수 간의 조건부 독립을 표현한 **방향성 그래프**(directed graph)와, **조건부 확률분포**들로 확률분포를 표현한 것
  - 노드 : 확률 변수
  - 간선 : 의존관계
- $P(N, A, E, B) = P(N|A, E, B)P(A|E, B)P(E|B)P(B) = P(N|A)P(A|E, B)P(E)P(B)$






# 베이지안 망

## ❖ 베이지안 망 - cont.

$$\begin{aligned} P(N, A, E, B) &= P(N|A, E, B)P(A|E, B)P(E|B)P(B) \\ &= P(N|A)P(A|E, B)P(E)P(B) \end{aligned}$$

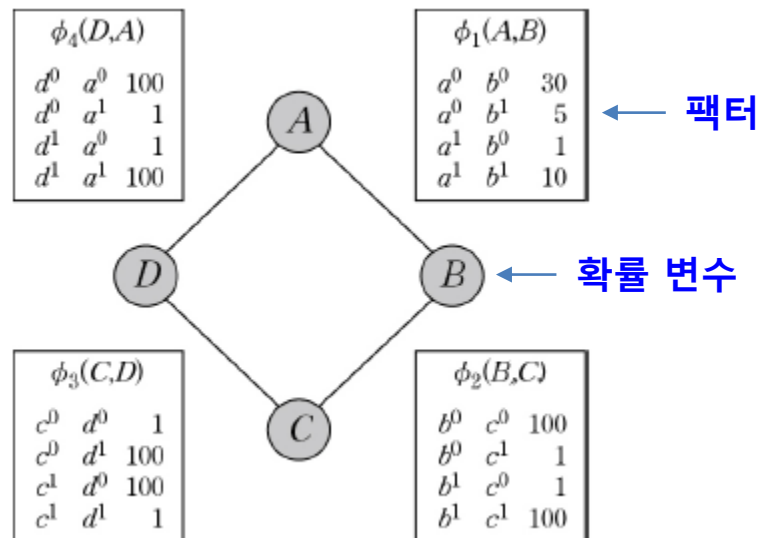


$$\begin{aligned} P(N=F, A=F, E=F, B=F) \\ &= P(N=F|A=F)P(A=F|E=F, B=F)P(E=F)P(B=F) \\ &= 0.9 \cdot 0.99 \cdot 0.9 \cdot 0.7 = 0.56133 \end{aligned}$$

### 3. 마르코프 랜덤 필드

#### ❖ 마르코프 랜덤 필드(Markov random field)

- 마르코프 망(Markov network)라고도 함
- 확률분포를 **무방향 그래프**(undirected graph)를 사용하여 표현
- 확률변수들의 값의 조합에 대한 값을 부여한 **팩터**(factor, potential function)
  - 각 조합에 대한 **호응 정도**(affinity, compatibility) 정의
    - 호응 정도는 0이상의 실수 값




# 마르코프 랜덤 필드

## ❖ 마르코프 랜덤 필드(Markov network) – cont.

- 확률변수들의 값의 조합에 대한 값을 부여한 **팩터(factor)들의 곱**에 **비례**하는 **확률값** 표현
- 분할함수(partition function) 값
  - 팩터 곱들의 전체 합
- **확률 = (팩터의 곱)/(분할함수의 값)**

$$P(a^0, b^0, c^0, d^0) = 300,000 / 7,201,840 = 0.04$$



A	B	C	D	팩터의 곱	확률
$a^0$	$b^0$	$c^0$	$d^0$	300,000	0.04
$a^0$	$b^0$	$c^0$	$d^1$	300,000	0.04
$a^0$	$b^0$	$c^1$	$d^0$	300,000	0.04
$a^0$	$b^0$	$c^1$	$d^1$	30	$4.1 \cdot 10^{-6}$
$a^0$	$b^1$	$c^0$	$d^0$	500	$6.9 \cdot 10^{-5}$
$a^0$	$b^1$	$c^0$	$d^1$	500	$6.9 \cdot 10^{-5}$
$a^0$	$b^1$	$c^1$	$d^0$	5,000,000	0.69
$a^0$	$b^1$	$c^1$	$d^1$	500	$6.9 \cdot 10^{-5}$
$a^1$	$b^0$	$c^0$	$d^0$	100	$1.4 \cdot 10^{-5}$
$a^1$	$b^0$	$c^0$	$d^1$	1,000,000	0.14
$a^1$	$b^0$	$c^1$	$d^0$	100	$1.4 \cdot 10^{-5}$
$a^1$	$b^0$	$c^1$	$d^1$	100	$1.4 \cdot 10^{-5}$
$a^1$	$b^1$	$c^0$	$d^0$	10	$1.4 \cdot 10^{-6}$
$a^1$	$b^1$	$c^0$	$d^1$	100,000	0.014
$a^1$	$b^1$	$c^1$	$d^0$	100,000	0.014
$a^1$	$b^1$	$c^1$	$d^1$	100,000	0.014

팩터곱의 합(분할함수의 값): 7, 201, 840

# 확률 그래프 모델

## ❖ 연속인 확률변수가 포함된 확률 분포

- 표(table)를 사용한 표현 곤란
- **함수식**을 이용한 표현
  - 베이저안 망 : 조건부 확률 값 출력 함수 사용
  - 마르코프 랜덤 필드 : 지수함수와 같은 함수로 팩터 정의

$$\phi(X_i, X_j, X_k) = \exp(f(X_i, X_j, X_k)) : \text{팩터(factor)}$$

$X_i, X_j, X_k$  : 확률 변수

$f(X_i, X_j, X_k)$  : 특정 특징의 유무나 정도 등을 계산하는 함수식

예.  $f(X_1, X_2, X_3) = 2X_1 - 3X_2X_3$   
 $f(X_1, X_2) = X_1, X_2$ 가 공통으로 겹치는 정도  
 $f(X_1) = X_1$ 을 알고리즘 A로 처리한 결과값

$$f(X_1, X_2) = \begin{cases} 1.5 & \text{if } X_1 = X_2 \\ 0.1 & \text{otherwise} \end{cases}$$
$$f(X_1, X_2) = \begin{cases} 0.2 & \text{if } X_1 = X_2 \\ 1.3 & \text{otherwise} \end{cases}$$

## 4. 조건부 랜덤 필드

### ❖ 조건부 랜덤 필드(conditional random field, **CRF**)

- 조건부 확률분포를 표현하는 마르코프 랜덤 필드
- $X$  : 관측되는 대상이나 입력을 나타내는 확률변수들의 집합
- $Y$  : 추정하거나 예측하는 대상을 나타내는 확률변수들의 집합
- 관측값  $x$ 가 주어질 때  $Y$ 의 확률계산
- $\{\phi_1(D_1), \phi_2(D_2), \dots, \phi_n(D_n)\}$  :  $Y$ 의 확률변수를 하나라도 포함한 팩터의 집합
- 조건부 확률 정의

$$P(Y|X) = \frac{1}{Z(X)} \tilde{P}(X, Y)$$

$$\tilde{P}(X, Y) = \prod_{i=1}^m \phi_i(D_i)$$

$$Z(X) = \sum_Y \tilde{P}(Y, X) \quad \text{분할 함수(partition function)}$$


# 조건부 랜덤 필드

## ❖ 조건부 랜덤 필드의 예

- 자연어 품사 태깅

입력	$X_1$	$X_2$	$X_3$	$X_4$	$X_5$	$X_6$
	The boy knocks at the door.					
출력	D	N	V	P	D	N
	$Y_1$	$Y_2$	$Y_3$	$Y_4$	$Y_5$	$Y_6$

$$\mathbf{X} = \{X_1, X_2, \dots, X_n\}$$



$$P(Y|X) = \frac{1}{Z} \exp\left(\sum_j \sum_{i=1}^{n-1} w_i f_j(Y_{i+1}, Y_i, \mathbf{X}, i) + \sum_j \sum_{i=1}^{n-1} v_i g_j(Y_i, \mathbf{X}, i)\right)$$

$$f_j(Y_{i+1}, Y_i, \mathbf{X}, i) = \begin{cases} 1 & \text{if } Y_{i+1} = P, Y_i = V, \text{ and } X_i = \text{knocks} \\ 0 & \text{otherwise} \end{cases}$$

$$g_j(Y_i, \mathbf{X}, i) = \begin{cases} 1 & \text{if } Y_i = V, \text{ and } X_i = \text{knocks} \\ 0 & \text{otherwise} \end{cases}$$

# 5. 로그-선형 모델

## ❖ 로그-선형 모델(log-linear model)

### ■ 팩터가 지수 함수로 표현되는 마르코프 랜덤 필드 모델

- $\mathbf{X} = \{X_1, X_2, \dots, X_m\}$ : 확률변수의 집합
- 팩터의 형태

$$\phi_i = \exp(-w_i f_i(D_i))$$

계수(parameter)

확률변수 집합  $D_i$ 에 정의된 함수: 특징 추출

### • 확률 분포의 표현

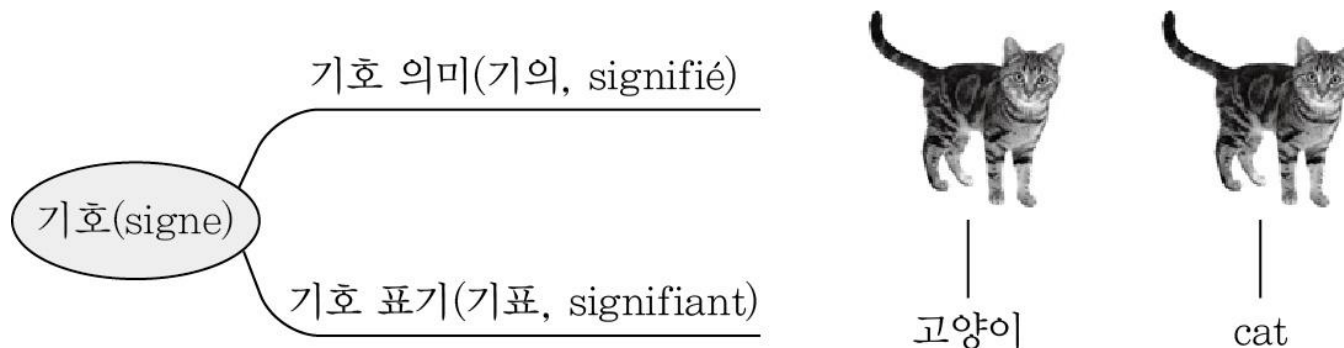
$$P(X_1, X_2, \dots, X_n) = \frac{1}{Z} \exp\left[-\sum_{i=1}^K w_i f_i(D_i)\right]$$

분할 함수(partition function)

## 6. 심볼 그라운드링 문제와 프레임 문제

### ❖ 심볼 그라운드링 문제

- '고양이는 귀엽다'라는 지식 표현
  - '고양이'와 '귀엽다'는 대상 또는 개념을 가리키는 **기호**(symbol) 사용



- 기호의 **표기**와 **의미**가 자의적인 관계
- 기호를 이해하는 **문화 체계** 속에서 필연화
- 심볼 그라운드링(symbol grounding)
  - 기호 표기를 실제 세계의 **의미**와 **연결**시키는 것



# 심볼 그라운드링 문제

## ❖ 심볼 그라운드링 문제 – cont.

- 기호 표기로 표현되어 있는 지식에 대해서, 컴퓨터는 심볼 그라운드링을 할 수 있는 능력이 없음
- 실제 세계와 컴퓨터의 기호 표기 사이의 심볼 그라운드링을 인간이 대신 수행
- 기호 표기를 실제 세계의 의미와 직접 연결시킬 수 없다는 것
- 딥러닝 기술 발전은 심볼 그라운드링 문제에 해결에 기여 예상

# 프레임 문제

## ❖ 프레임(frame) 문제

- 사고범위 문제(思考範圍問題)
- 어떤 작업을 수행할 때 **관련 있는 지식만** 꺼내서 사용한다는 것은 지극히 자연스럽고 당연하지만, 인공지능에서는 이러한 일이 쉽지 **않다**는 것



그림 3.28 프레임 문제

# 7. CYC 프로젝트

## ❖ 상식의 필요성

- 추론 등을 위해 **상식**(commonsense)의 활용 중요
  - 상식의 예
    - 물체를 공중에서 놓으면 아래로 떨어진다.
    - 사람은 태어나기 전에는 존재하지 않는다.
    - 물고기는 물에서 살며 물 밖으로 나오면 죽는다.
    - 빵은 빵가게에서 산다.
    - 물컵이 넘어지면 물이 나온다.

## • 상식의 적용 예 - 기계번역

He saw a girl in the garden with a telescope.

그는 망원경으로 정원에 있는 소녀를 보았다.

그는 정원에서 망원경으로 소녀를 보았다.

그는 소녀가 정원에서 망원경을 들고 있는 것을 보았다.

정원에서 그는 망원경을 들고 있는 소녀를 보았다.

# CYC 프로젝트

## ❖ CYC 프로젝트

- **상식적인 추론**을 하는데 필요한 방대한 **지식을 추출하여 표현**하는 프로젝트
- **일차 술어 논리**를 사용 지식 표현
- 1984년 르넷(Douglas Lenat) 시작
- 예. CYC의 예

`(#$isa #$DonaldTrump #$UnitedStatesPresident)` ; 도널드트럼프는 미국 대통령이다.

`(#$capitalCity #$France #$Paris)` ; 프랑스 수도는 파리이다.

`(#$implies ($and ($isa ?OBJ ?SUBSET) ($genls ?SUBSET ?SUPERSET))`

`($isa ?OBJ ?SUPERSET))` ; OBJ가 SUBSET의 사례이고, SUBSET이

SUPERSET에 속하면, OBJ는 SUPERSET의 사례이다. (규칙표현의 예)

`(#$relationAllExists #$biologicalMother #$ChordataPhylum #$FemaleAnimal)`

; 모든 ChordataPhylum에 속하는 개체에게는 어머니(biologicalMother)인

; 여성(FemaleAnimal)이 있다. (존재한정사가 있는 문장)

# [실습] 확률 그래프 모델


## ❖ pgmpy 패키지 사용

- 다양한 확률 그래프 모델 지원

```
!pip install pgmpy
```

## ❖ 베이지안 망 정의 및 추론

```
1 import networkx as nx
2 from networkx.drawing.nx_pydot import to_pydot
3 from IPython.core.display import Image
4
5 g = nx.DiGraph()
6 g.add_edge("E", "A")
7 g.add_edge("B", "A")
8 g.add_edge("A", "N")
9 d = to_pydot(g)
10 d.get_node("N")[0].set_fillcolor("gray")
11 d.get_node("N")[0].set_style("filled")
12 d.set_dpi(300)
13 d.set_margin(0.2)
14 Image(d.create_png(), width=200)
```



```

1 from pgmpy.factors.discrete import TabularCPD
2 import numpy as np
3
4 # 지진(Earthquake) 발생 확률 분포
5 P_E = TabularCPD('E', 2, [[0.9], [0.1]], state_names={'E': ['F', 'T']})
6 print('P(E)')
7 print(P_E)
8
9 # 절도(Burglary) 발생 확률분포
10 P_B = TabularCPD('B', 2, [[0.7], [0.3]], state_names={'B': ['F', 'T']})
11 print('P(B)')
12 print(P_B)
13
14 # 경보(Alarm) 발생 확률 분포
15 P_A_I_EB = TabularCPD('A', 2, [[0.99, 0.1, 0.3, 0.01], [0.01, 0.9, 0.7, 0.99]],
16                             evidence=['E', 'B'], evidence_card=[2, 2],
17                             state_names={'A': ['F', 'T'], 'E': ['F', 'T'], 'B': ['F', 'T']})
18 print('P(A|EB)')
19 print(P_A_I_EB)
20
21 # 이웃(Neighbor) 전화 확률 분포
22 P_N_I_A = TabularCPD('N', 2,
23                       np.array([[0.9, 0.2], [0.1, 0.8]]),
24                       evidence=['A'], evidence_card=[2],
25                       state_names={'N': ['F', 'T'], 'A': ['F', 'T']})
26 print('P(N|A)')
27 print(P_N_I_A)

```

P(E)

E(F)	0.9
E(T)	0.1

P(B)

B(F)	0.7
B(T)	0.3

P(A|EB)

E	E(F)	E(T)	E(T)	E(T)
B	B(F)	B(T)	B(F)	B(T)
A(F)	0.99	0.1	0.3	0.01
A(T)	0.01	0.9	0.7	0.99

P(N|A)

A	A(F)	A(T)
N(F)	0.9	0.2
N(T)	0.1	0.8

```

1 from pgmpy.models import BayesianModel
2
3 # 베이지안 망 구조 정의
4 model = BayesianModel([('E', 'A'), ('B', 'A'), ('A', 'N')])
5 model.add_cpds(P_E, P_B, P_A_I_EB, P_N_I_A) # 확률분포 등록
6 model.check_model()

```

True

```

1 from pgmpy.inference import VariableElimination
2
3 # 베이지안 망의 추론
4 infer = VariableElimination(model)
5 A_dist = infer.query(['A'])
6 print('P(A)')
7 print(A_dist)
8
9 N_I_EF_BT = infer.query(['N'], evidence={'E': 'F', 'B': 'T'})
10 print('P(N | E=F, B=T)')
11 print(N_I_EF_BT)
12
13 N_I_AF_BT = infer.query(['N'], evidence={'A': 'F', 'B': 'T'})
14 print('P(N | A=F, B=T)')
15 print(N_I_AF_BT)

```

+-----+-----+	
A	phi(A)
+-----+-----+	
A(F)	0.6720
+-----+-----+	
A(T)	0.3280
+-----+-----+	

P(N | E=F, B=T)


+-----+-----+	
N	phi(N)
+-----+-----+	
N(F)	0.2700
+-----+-----+	
N(T)	0.7300
+-----+-----+	

P(N | A=F, B=T)

+-----+-----+	
N	phi(N)
+-----+-----+	
N(F)	0.9000
+-----+-----+	
N(T)	0.1000
+-----+-----+	

## ❖ 마르코프 랜덤 필드의 예

```
1 import networkx as nx
2 from IPython.core.display import Image
3 from networkx.drawing.nx_pydot import to_pydot
4
5 g1 = nx.Graph()
6 g1.add_edge("A", "B")
7 g1.add_edge("D", "A")
8 g1.add_edge("B", "C")
9 g1.add_edge("C", "D")
10
11 d1 = to_pydot(g1)
12 d1.set_dpi(300)
13 d1.set_margin(0.5)
14 Image(d1.create_png(), width=300)
```






```

1 from pgmpy.models import MarkovModel
2 from pgmpy.factors.discrete import DiscreteFactor
3
4 # 마르코프 랜덤 필드(마르코프 모델) 모델 정의
5 model = MarkovModel([('A', 'B'), ('B', 'C'), ('C', 'D'), ('D', 'A')])
6 factor1 = DiscreteFactor(['A', 'B'], [2, 2], [30, 5, 1, 10], state_names={'A': [0,1], 'B': [0,1]})
7 factor2 = DiscreteFactor(['B', 'C'], [2, 2], [100, 1, 1, 100], state_names={'B': [0,1], 'C': [0,1]})
8 factor3 = DiscreteFactor(['C', 'D'], [2, 2], [1, 100, 100, 1], state_names={'C': [0,1], 'D': [0,1]})
9 factor4 = DiscreteFactor(['D', 'A'], [2, 2], [100, 1, 1, 100], state_names={'D': [0,1], 'A': [0,1]})
10 model.add_factors(factor1, factor2, factor3, factor4)
11 print('모델의 타당성: ', model.check_model())

```

모델의 타당성: True



```

1 import numpy as np
2 pf_value = model.get_partition_function()
3 print('\n분할 함수의 값: ', pf_value)
4
5 infer = VariableElimination(model) # 추론 객체 생성
6
7 phi_ABCD = infer.query(['A', 'B', 'C', 'D']) # 전체 분포 phi(A,B,C,D)
8 print('phi(A,B,C,D)')
9 print(phi_ABCD)
10 P_ABCD = phi_ABCD.values/pf_value # 확률 = (팩터의 곱)/(분할 함수의 값)
11 PABCD = np.reshape(P_ABCD, -1)
12 for val in PABCD: # 확률의 출력
13     print(val, '\n')
14
15 A_dist = infer.query(['A']) # A의 분포 phi(A)
16 print('phi(A)')
17 print(A_dist)
18 P_A = A_dist.values/np.sum(A_dist.values)
19 for val in P_A:
20     print(val, '\n')
21
22 AIB0C1_dist = infer.query(['A'], evidence={'B':0, 'C':1}) # phi(A|B=0,C=1)
23 print('phi(A|B=0,C=1)')
24 print(AIB0C1_dist)
25 P_AIB0C1 = AIB0C1_dist.values/np.sum(AIB0C1_dist.values)
26 for val in P_AIB0C1:
27     print(val, '\n')

```

분할 함수의 값: 7201840.0

phi(A,B,C,D)				
C	D	A	B	phi(C,D,A,B)
C(0)	D(0)	A(0)	B(0)	300000.0000
C(0)	D(0)	A(0)	B(1)	500.0000
C(0)	D(0)	A(1)	B(0)	100.0000
C(0)	D(0)	A(1)	B(1)	10.0000
C(0)	D(1)	A(0)	B(0)	300000.0000
C(0)	D(1)	A(0)	B(1)	500.0000
C(0)	D(1)	A(1)	B(0)	1000000.0000
C(0)	D(1)	A(1)	B(1)	100000.0000
C(1)	D(0)	A(0)	B(0)	300000.0000
C(1)	D(0)	A(0)	B(1)	5000000.0000
C(1)	D(0)	A(1)	B(0)	100.0000
C(1)	D(0)	A(1)	B(1)	100000.0000
C(1)	D(1)	A(0)	B(0)	30.0000
C(1)	D(1)	A(0)	B(1)	500.0000
C(1)	D(1)	A(1)	B(0)	100.0000
C(1)	D(1)	A(1)	B(1)	100000.0000

phi(A)		
A	phi(A)	
A(0)	5901530.0000	0.8194475300756473
A(1)	1300310.0000	0.18055246992435267

phi(A B=0,C=1)		
A	phi(A)	
A(0)	300030.0000	0.9993338440528928
A(1)	200.0000	0.0006661559471072178

# Quiz

## ❖ 확률 분포에 대한 설명으로 적합하지 않는 것을 선택하시오.

- ① 관심대상을 표현하는 확률변수들에 대한 결합확률 분포를 가지고 있으면 다양한 상황에 대한 확률적 추론을 할 수 있다.
- ② 결합확률 분포를 가지고 있으면 특정한 조건부 확률이나 일부 확률변수에 대한 결합확률 분포를 계산할 수 있다.
- ③ 확률분포를 사용하여 불확실한 사건이나 지식을 표현할 수 있다.
- ④ 확률변수들은 서로 독립적이기 때문에 어떤 확률변수로 다른 확률변수에 대한 정보를 유추하는 것은 불가능하다.

## ❖ 확률에 대한 설명으로 적합하지 않는 것을 선택하시오.

- ① 확률변수 A가 갖는 값이 확률변수 B가 갖는 값과 전혀 연관이 없을 때 이들 확률변수는 서로 독립이라고 한다.
- ② 모든 확률변수가 서로 독립이면, 결합확률 분포는 확률분포들의 곱으로 표현할 수 없다.
- ③ 특정 확률변수 C의 값이 주어지면 확률변수 A와 B가 서로 독립일 때, C가 주어질 때 A와 B는 조건부 독립이라고 한다.
- ④ 조건부 독립의 성질을 갖는 확률변수들이 있으면 결합확률 분포를 확률분포들의 곱으로 표현할 수 있다.

# Quiz

## ❖ 확률 그래프 모델에 대한 설명으로 적합하지 않는 것을 선택하시오.

- ① 확률 그래프 모델은 그래프 구조를 이용하여 확률변수간의 연관관계를 표현하여 확률분포에 표현 및 추론을 용이하게 한다.
- ② 마르코프 랜덤 필드에서 팩터는 지수함수로 정의해야 한다.
- ③ 마르코프 랜덤 필드에서는 확률변수들의 값의 조합별로 서로 부합되는 정도를 나타내는 호응정도값을 부여하는 팩터를 결정하고, 이 팩터들의 곱을 사용하여 확률값을 결정한다.
- ④ 베이지안 망에서는 방향 그래프를 사용하여 조건부 독립의 관계를 표현한다.

## ❖ 다음 지식표현에 관련한 설명으로 적합하지 않는 것을 선택하시오.

- ① 일상 상황에 대한 문제 해결을 위해서는 상식에 대한 지식이 필수적이며, 상식을 일차 술어 논리 형태의 지식을 구축하여, 이러한 문제 해결은 비교적 쉽게 해결할 수 있다
- ② 많은 지식을 포함하고 있는 시스템에 현재 해결하려는 문제에 관련된 지식을 선택하는 과정에서 시간이 너무 오래 걸릴 수 있는 문제를 프레임 문제라고 한다.
- ③ 기호 표기를 실제 세계의 의미와 연결시키는 것을 심볼 그라운드링이라 한다.
- ④ 기호로 지식을 표현하는 컴퓨터는 심볼 그라운드링을 할 수 있는 능력이 아직은 없다.