

지식표현과 추론

확률 그래프 모델과 지식 표현의 문제

이건명

충북대학교 소프트웨어학과

인공지능 : 튜링 테스트에서 딥러닝까지

학습 내용

- 확률 그래프 모델의 개념에 대해서 알아본다.
- 베이지안 망, 마르코프 랜덤 필드, 조건부 랜덤 필드, 로그-선형 모델의 형태에 대해서 알아본다.
- 심볼 그라운드링 문제와 프레임 문제에 대해서 알아본다.
- 상식의 표현에 대해서 알아본다.

1. 확률 그래프 모델

❖ 확률 그래프 모델(probabilistic graphical model)

- 확률 이론과 그래프 이론을 결합하여 **확률분포**(probability distribution)를 **표현**하고,
관심있는 대상(**확률변수**)에 대한 **확률** 또는 **확률분포**를 **계산**할 수 있는 모델
- 확률분포를 이용한 지식표현을 하고 확률적 추론
- 베이지안 망
- 마르코프 랜덤 필드(마르코프 망)
- 조건부 랜덤 필드
- 로그-선형 모델

확률 그래프 모델

❖ 확률 그래프 모델(probabilistic graphical model)

▪ 예. 절도 경보 문제

- 절도가 발생하거나 지진이 발생하면 경보 발생
- 경보가 울리면 이웃이 전화

• 불확실한 요소가 있어 확률로 표현

– 확률변수(random variable)

- » 경보 작동(**A**; alarm)
- » 절도 발생(**B**; burglary)
- » 지진 발생(**E**; earthquake)
- » 이웃 전화(**N**; neighbor call)



확률 그래프 모델

▪ 절도 경보 문제의 확률분포에 의한 지식표현

- 지진 발생(E), 절도 발생(B), 경보 생성(A), 이웃전화 (N)
- 결합확률 분포로 표현

| <i>E</i> | <i>B</i> | <i>A</i> | <i>N</i> | 확률 |
|----------|----------|----------|----------|---------|
| F | F | F | F | 0.56133 |
| F | F | F | T | 0.06237 |
| F | F | T | F | 0.00126 |
| F | F | T | T | 0.00504 |
| F | T | F | F | 0.0243 |
| F | T | F | T | 0.0027 |
| F | T | T | F | 0.0486 |
| F | T | T | T | 0.1944 |
| T | F | F | F | 0.0189 |
| T | F | F | T | 0.0021 |
| T | F | T | F | 0.0098 |
| T | F | T | T | 0.0392 |
| T | T | F | F | 0.00027 |
| T | T | F | T | 0.00003 |
| T | T | T | F | 0.00594 |
| T | T | T | T | 0.02376 |



경보가 울릴 때 이웃이 전화할 확률은?

$$P(N = T | A = T) = ?$$

이웃이 전화했을 때 도둑이 들었을 확률은?

$$P(B = T | N = T) = ?$$

확률 그래프 모델

❖ 조건부 독립과 확률분포의 인수분해(factorization)

- 사건의 독립(independence)
 - $P(E, B) = P(E)P(B)$
- 조건부 독립(conditional independence) 성질 이용
 - $P(N, A|E) = P(N|E)P(A|E)$
- 확률분포의 인수분해
 - $P(A, B) = P(A|B)P(B)$
 - $P(A_1, A_2, A_3, A_4) = P(A_1|A_2, A_3, A_4)P(A_2|A_3, A_4)P(A_3|A_4)P(A_4)$

확률 그래프 모델

❖ 조건부 독립을 이용한 확률분포의 인수 분해

$$P(N, A, E, B) = P(N|A, E, B)P(A|E, B)P(E|B)P(B)$$

만족하는 조건부 독립 성질

$$P(N|A, E, B) = P(N|A)$$

$$P(E|B) = P(E)$$

$$= P(N|A)P(A|E, B)P(E)P(B)$$

| A | N | |
|---|-----|-----|
| | F | T |
| F | 0.9 | 0.1 |
| T | 0.2 | 0.8 |

| E | B | A | |
|---|---|------|------|
| | | F | T |
| F | F | 0.99 | 0.01 |
| F | T | 0.1 | 0.9 |
| T | F | 0.3 | 0.7 |
| T | T | 0.01 | 0.99 |

| E | |
|-----|-----|
| F | T |
| 0.9 | 0.1 |

| B | |
|-----|-----|
| F | T |
| 0.7 | 0.3 |

| E | B | A | N | 확률 |
|---|---|---|---|---------|
| F | F | F | F | 0.56133 |
| F | F | F | T | 0.06237 |
| F | F | T | F | 0.00126 |
| F | F | T | T | 0.00504 |
| F | T | F | F | 0.0243 |
| F | T | F | T | 0.0027 |
| F | T | T | F | 0.0486 |
| F | T | T | T | 0.1944 |
| T | F | F | F | 0.0189 |
| T | F | F | T | 0.0021 |
| T | F | T | F | 0.0098 |
| T | F | T | T | 0.0392 |
| T | T | F | F | 0.00027 |
| T | T | F | T | 0.00003 |
| T | T | T | F | 0.00594 |
| T | T | T | T | 0.02376 |

$$P(N = T, A = T, E = F, B = T)$$

$$= P(N = T|A = T)P(A = T|E = F, B = T)P(E = F)P(B = T)$$


$$= 0.8 \times 0.9 \times 0.9 \times 0.3$$

$$= 0.1944$$

2. 베이지안 망

❖ 베이지안 망(Bayesian network)


- 확률변수 간의 조건부 독립을 표현한 **방향성 그래프**(directed graph)와, **조건부 확률분포**들로 확률분포를 표현한 것
 - 노드 : 확률 변수
 - 간선 : 의존관계
- $P(N, A, E, B) = P(N|A, E, B)P(A|E, B)P(E|B)P(B) = P(N|A)P(A|E, B)P(E)P(B)$



베이저안 망

❖ 베이저안 망 - cont.

$$\begin{aligned} P(N, A, E, B) &= P(N|A, E, B)P(A|E, B)P(E|B)P(B) \\ &= P(N|A)P(A|E, B)P(E)P(B) \end{aligned}$$

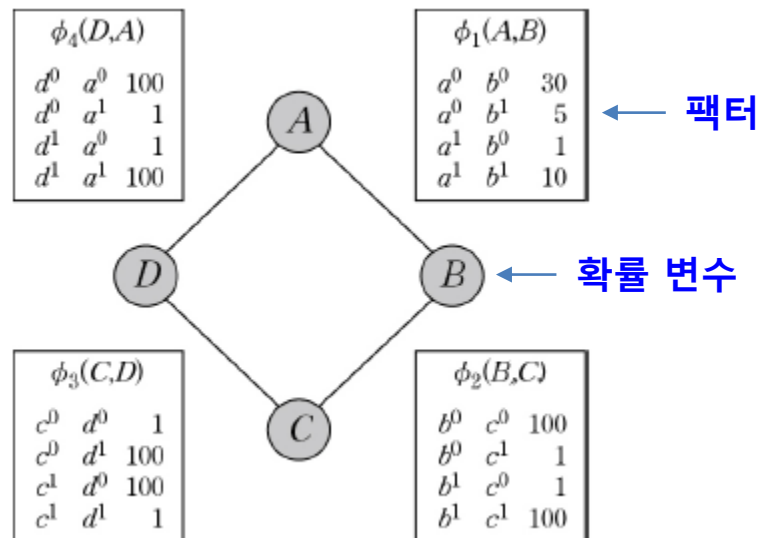


$$\begin{aligned} P(N=F, A=F, E=F, B=F) \\ &= P(N=F|A=F)P(A=F|E=F, B=F)P(E=F)P(B=F) \\ &= 0.9 \cdot 0.99 \cdot 0.9 \cdot 0.7 = 0.56133 \end{aligned}$$

3. 마르코프 랜덤 필드

❖ 마르코프 랜덤 필드(Markov random field)

- 마르코프 망(Markov network)라고도 함
- 확률분포를 **무방향 그래프**(undirected graph)를 사용하여 표현
- 확률변수들의 값의 조합에 대한 값을 부여한 **팩터**(factor, potential function)
 - 각 조합에 대한 **호응 정도**(affinity, compatibility) 정의
 - 호응 정도는 0이상의 실수 값




마르코프 랜덤 필드

❖ 마르코프 랜덤 필드(Markov network) – cont.

- 확률변수들의 값의 조합에 대한 값을 부여한 **팩터(factor)들의 곱**에 **비례**하는 **확률값** 표현
- 분할함수(partition function) 값
 - 팩터 곱들의 전체 합
- **확률 = (팩터의 곱)/(분할함수의 값)**

$$P(a^0, b^0, c^0, d^0) = 300,000 / 7,201,840 = 0.04$$



| A | B | C | D | 팩터의 곱 | 확률 |
|----------------|----------------|----------------|----------------|-----------|------------------------|
| a ⁰ | b ⁰ | c ⁰ | d ⁰ | 300,000 | 0.04 |
| a ⁰ | b ⁰ | c ⁰ | d ¹ | 300,000 | 0.04 |
| a ⁰ | b ⁰ | c ¹ | d ⁰ | 300,000 | 0.04 |
| a ⁰ | b ⁰ | c ¹ | d ¹ | 30 | 4.1 · 10 ⁻⁶ |
| a ⁰ | b ¹ | c ⁰ | d ⁰ | 500 | 6.9 · 10 ⁻⁵ |
| a ⁰ | b ¹ | c ⁰ | d ¹ | 500 | 6.9 · 10 ⁻⁵ |
| a ⁰ | b ¹ | c ¹ | d ⁰ | 5,000,000 | 0.69 |
| a ⁰ | b ¹ | c ¹ | d ¹ | 500 | 6.9 · 10 ⁻⁵ |
| a ¹ | b ⁰ | c ⁰ | d ⁰ | 100 | 1.4 · 10 ⁻⁵ |
| a ¹ | b ⁰ | c ⁰ | d ¹ | 1,000,000 | 0.14 |
| a ¹ | b ⁰ | c ¹ | d ⁰ | 100 | 1.4 · 10 ⁻⁵ |
| a ¹ | b ⁰ | c ¹ | d ¹ | 100 | 1.4 · 10 ⁻⁵ |
| a ¹ | b ¹ | c ⁰ | d ⁰ | 10 | 1.4 · 10 ⁻⁶ |
| a ¹ | b ¹ | c ⁰ | d ¹ | 100,000 | 0.014 |
| a ¹ | b ¹ | c ¹ | d ⁰ | 100,000 | 0.014 |
| a ¹ | b ¹ | c ¹ | d ¹ | 100,000 | 0.014 |

팩터곱의 합(분할함수의 값): 7, 201, 840

확률 그래프 모델

❖ 연속인 확률변수가 포함된 확률 분포

- 표(table)를 사용한 표현 곤란
- **함수식**을 이용한 표현
 - 베이지안 망 : 조건부 확률 값 출력 함수 사용
 - 마르코프 랜덤 필드 : 지수함수와 같은 함수로 팩터 정의

$$\phi(X_i, X_j, X_k) = \exp(f(X_i, X_j, X_k)) : \text{팩터(factor)}$$

X_i, X_j, X_k : 확률 변수

$f(X_i, X_j, X_k)$: 특정 특징의 유무나 정도 등을 계산하는 함수식

예. $f(X_1, X_2, X_3) = 2X_1 - 3X_2X_3$
 $f(X_1, X_2) = X_1, X_2$ 가 공통으로 겹치는 정도
 $f(X_1) = X_1$ 을 알고리즘 A로 처리한 결과값

$$f(X_1, X_2) = \begin{cases} 1.5 & \text{if } X_1 = X_2 \\ 0.1 & \text{otherwise} \end{cases}$$
$$f(X_1, X_2) = \begin{cases} 0.2 & \text{if } X_1 = X_2 \\ 1.3 & \text{otherwise} \end{cases}$$

4. 조건부 랜덤 필드

❖ 조건부 랜덤 필드(conditional random field, **CRF**)

- 조건부 확률분포를 표현하는 마르코프 랜덤 필드
- X : 관측되는 대상이나 입력을 나타내는 확률변수들의 집합
- Y : 추정하거나 예측하는 대상을 나타내는 확률변수들의 집합
- 관측값 x 가 주어질 때 Y 의 확률계산
- $\{\phi_1(D_1), \phi_2(D_2), \dots, \phi_n(D_n)\}$: Y 의 확률변수를 하나라도 포함한 팩터의 집합
- 조건부 확률 정의

$$P(Y|X) = \frac{1}{Z(X)} \tilde{P}(X, Y)$$

$$\tilde{P}(X, Y) = \prod_{i=1}^m \phi_i(D_i)$$

$$Z(X) = \sum_Y \tilde{P}(Y, X) \quad \text{분할 함수(partition function)}$$


조건부 랜덤 필드

❖ 조건부 랜덤 필드의 예

- 자연어 품사 태깅

| | | | | | | |
|----|-----------------------------|-------|-------|-------|-------|-------|
| 입력 | X_1 | X_2 | X_3 | X_4 | X_5 | X_6 |
| | The boy knocks at the door. | | | | | |
| 출력 | D | N | V | P | D | N |
| | Y_1 | Y_2 | Y_3 | Y_4 | Y_5 | Y_6 |

$$\mathbf{X} = \{X_1, X_2, \dots, X_n\}$$



$$P(Y|X) = \frac{1}{Z} \exp\left(\sum_j \sum_{i=1}^{n-1} w_i f_j(Y_{i+1}, Y_i, \mathbf{X}, i) + \sum_j \sum_{i=1}^{n-1} v_i g_j(Y_i, \mathbf{X}, i)\right)$$

$$f_j(Y_{i+1}, Y_i, \mathbf{X}, i) = \begin{cases} 1 & \text{if } Y_{i+1} = P, Y_i = V, \text{ and } X_i = \text{knocks} \\ 0 & \text{otherwise} \end{cases}$$

$$g_j(Y_i, \mathbf{X}, i) = \begin{cases} 1 & \text{if } Y_i = V, \text{ and } X_i = \text{knocks} \\ 0 & \text{otherwise} \end{cases}$$

5. 로그-선형 모델

❖ 로그-선형 모델(log-linear model)

■ 팩터가 지수 함수로 표현되는 마르코프 랜덤 필드 모델

- $\mathbf{X} = \{X_1, X_2, \dots, X_m\}$: 확률변수의 집합
- 팩터의 형태

$$\phi_i = \exp(-w_i f_i(D_i))$$

계수(parameter)

확률변수 집합 D_i 에 정의된 함수: 특징 추출

• 확률 분포의 표현

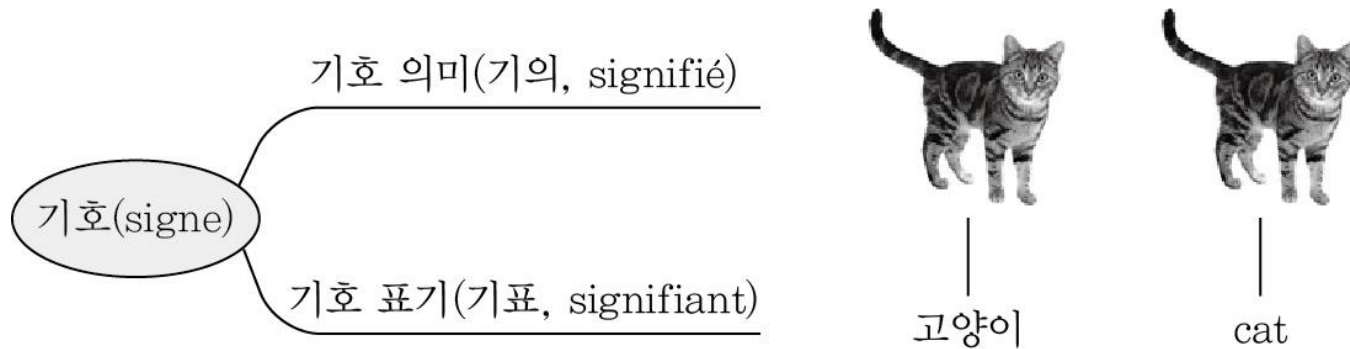
$$P(X_1, X_2, \dots, X_n) = \frac{1}{Z} \exp \left[- \sum_{i=1}^K w_i f_i(D_i) \right]$$

분할 함수(partition function)

6. 심볼 그라운드링 문제와 프레임 문제

❖ 심볼 그라운드링 문제

- '고양이는 귀엽다'라는 지식 표현
 - '고양이'와 '귀엽다'는 대상 또는 개념을 가리키는 **기호**(symbol) 사용



- 기호의 **표기**와 **의미**가 자의적인 관계
- 기호를 이해하는 **문화 체계** 속에서 필연화
- 심볼 그라운드링(symbol grounding)
 - 기호 표기를 실제 세계의 **의미**와 **연결**시키는 것

심볼 그라운드링 문제

❖ 심볼 그라운드링 문제 – cont.

- 기호 표기로 표현되어 있는 지식에 대해서, 컴퓨터는 심볼 그라운드링을 할 수 있는 능력이 없음
- 실제 세계와 컴퓨터의 기호 표기 사이의 심볼 그라운드링을 인간이 대신 수행
- 기호 표기를 실제 세계의 의미와 직접 연결시킬 수 없다는 것
- 딥러닝 기술 발전은 심볼 그라운드링 문제에 해결에 기여 예상

프레임 문제

❖ 프레임(frame) 문제

- 사고범위 문제(思考範圍問題)
- 어떤 작업을 수행할 때 **관련 있는 지식만** 꺼내서 사용한다는 것은 지극히 자연스럽고 당연하지만, 인공지능에서는 이러한 일이 쉽지 **않다**는 것



그림 3.28 프레임 문제

7. CYC 프로젝트

❖ 상식의 필요성

- 추론 등을 위해 **상식**(commonsense)의 활용 중요
 - 상식의 예
 - 물체를 공중에서 놓으면 아래로 떨어진다.
 - 사람은 태어나기 전에는 존재하지 않는다.
 - 물고기는 물에서 살며 물 밖으로 나오면 죽는다.
 - 빵은 빵가게에서 산다.
 - 물컵이 넘어지면 물이 나온다.

• 상식의 적용 예 - 기계번역

He saw a girl in the garden with a telescope.

그는 망원경으로 정원에 있는 소녀를 보았다.

그는 정원에서 망원경으로 소녀를 보았다.

그는 소녀가 정원에서 망원경을 들고 있는 것을 보았다.

정원에서 그는 망원경을 들고 있는 소녀를 보았다.

CYC 프로젝트

❖ CYC 프로젝트

- **상식적인 추론**을 하는데 필요한 방대한 **지식을 추출하여 표현**하는 프로젝트
- **일차 술어 논리**를 사용 지식 표현
- 1984년 르넷(Douglas Lenat) 시작
- 예. CYC의 예

`(#$isa #$DonaldTrump #$UnitedStatesPresident)` ; 도널드트럼프는 미국 대통령이다.

`(#$capitalCity #$France #$Paris)` ; 프랑스 수도는 파리이다.

`(#$implies ($and ($isa ?OBJ ?SUBSET) ($genls ?SUBSET ?SUPERSET))`

`($isa ?OBJ ?SUPERSET))` ; OBJ가 SUBSET의 사례이고, SUBSET이

SUPERSET에 속하면, OBJ는 SUPERSET의 사례이다. (규칙표현의 예)

`(#$relationAllExists #$biologicalMother #$ChordataPhylum #$FemaleAnimal)`

; 모든 ChordataPhylum에 속하는 개체에게는 어머니(biologicalMother)인

; 여성(FemaleAnimal)이 있다. (존재한정사가 있는 문장)

[실습] 확률 그래프 모델


❖ pgmpy 패키지 사용

- 다양한 확률 그래프 모델 지원

```
!pip install pgmpy
```

❖ 베이지안 망 정의 및 추론

```
1 import networkx as nx
2 from networkx.drawing.nx_pydot import to_pydot
3 from IPython.core.display import Image
4
5 g = nx.DiGraph()
6 g.add_edge("E", "A")
7 g.add_edge("B", "A")
8 g.add_edge("A", "N")
9 d = to_pydot(g)
10 d.get_node("N")[0].set_fillcolor("gray")
11 d.get_node("N")[0].set_style("filled")
12 d.set_dpi(300)
13 d.set_margin(0.2)
14 Image(d.create_png(), width=200)
```



```

1 from pgmpy.factors.discrete import TabularCPD
2 import numpy as np
3
4 # 지진(Earthquake) 발생 확률 분포
5 P_E = TabularCPD('E', 2, [[0.9], [0.1]], state_names={'E': ['F', 'T']})
6 print('P(E)')
7 print(P_E)
8
9 # 절도(Burglary) 발생 확률분포
10 P_B = TabularCPD('B', 2, [[0.7], [0.3]], state_names={'B': ['F', 'T']})
11 print('P(B)')
12 print(P_B)
13
14 # 경보(Alarm) 발생 확률 분포
15 P_A_I_EB = TabularCPD('A', 2, [[0.99, 0.1, 0.3, 0.01], [0.01, 0.9, 0.7, 0.99]],
16                             evidence=['E', 'B'], evidence_card=[2, 2],
17                             state_names={'A': ['F', 'T'], 'E': ['F', 'T'], 'B': ['F', 'T']})
18 print('P(A|EB)')
19 print(P_A_I_EB)
20
21 # 이웃(Neighbor) 전화 확률 분포
22 P_N_I_A = TabularCPD('N', 2,
23                       np.array([[0.9, 0.2], [0.1, 0.8]]),
24                       evidence=['A'], evidence_card=[2],
25                       state_names={'N': ['F', 'T'], 'A': ['F', 'T']})
26 print('P(N|A)')
27 print(P_N_I_A)

```

P(E)

| | | |
|--|------|-----|
| | | |
| | E(F) | 0.9 |
| | E(T) | 0.1 |

P(B)

| | | |
|--|------|-----|
| | | |
| | B(F) | 0.7 |
| | B(T) | 0.3 |

P(A|EB)

| | | | | | |
|--|------|------|------|------|------|
| | E | E(F) | E(T) | E(T) | |
| | B | B(F) | B(T) | B(F) | B(T) |
| | A(F) | 0.99 | 0.1 | 0.3 | 0.01 |
| | A(T) | 0.01 | 0.9 | 0.7 | 0.99 |

P(N|A)

| | | | | |
|--|------|------|------|--|
| | A | A(F) | A(T) | |
| | N(F) | 0.9 | 0.2 | |
| | N(T) | 0.1 | 0.8 | |

```

1 from pgmpy.models import BayesianModel
2
3 # 베이지안 망 구조 정의
4 model = BayesianModel([('E', 'A'), ('B', 'A'), ('A', 'N')])
5 model.add_cpds(P_E, P_B, P_A_I_EB, P_N_I_A) # 확률분포 등록
6 model.check_model()

```

True

```

1 from pgmpy.inference import VariableElimination
2
3 # 베이지안 망의 추론
4 infer = VariableElimination(model)
5 A_dist = infer.query(['A'])
6 print('P(A)')
7 print(A_dist)
8
9 N_I_EF_BT = infer.query(['N'], evidence={'E': 'F', 'B': 'T'})
10 print('P(N | E=F, B=T)')
11 print(N_I_EF_BT)
12
13 N_I_AF_BT = infer.query(['N'], evidence={'A': 'F', 'B': 'T'})
14 print('P(N | A=F, B=T)')
15 print(N_I_AF_BT)

```

| | |
|---------------|--------|
| +-----+-----+ | |
| A | phi(A) |
| +-----+-----+ | |
| A(F) | 0.6720 |
| +-----+-----+ | |
| A(T) | 0.3280 |
| +-----+-----+ | |

P(N | E=F, B=T)


| | |
|---------------|--------|
| +-----+-----+ | |
| N | phi(N) |
| +-----+-----+ | |
| N(F) | 0.2700 |
| +-----+-----+ | |
| N(T) | 0.7300 |
| +-----+-----+ | |

P(N | A=F, B=T)

| | |
|---------------|--------|
| +-----+-----+ | |
| N | phi(N) |
| +-----+-----+ | |
| N(F) | 0.9000 |
| +-----+-----+ | |
| N(T) | 0.1000 |
| +-----+-----+ | |

❖ 마르코프 랜덤 필드의 예

```
1 import networkx as nx
2 from IPython.core.display import Image
3 from networkx.drawing.nx_pydot import to_pydot
4
5 g1 = nx.Graph()
6 g1.add_edge("A", "B")
7 g1.add_edge("D", "A")
8 g1.add_edge("B", "C")
9 g1.add_edge("C", "D")
10
11 d1 = to_pydot(g1)
12 d1.set_dpi(300)
13 d1.set_margin(0.5)
14 Image(d1.create_png(), width=300)
```





```

1 from pgmpy.models import MarkovModel
2 from pgmpy.factors.discrete import DiscreteFactor
3
4 # 마르코프 랜덤 필드(마르코프 모델) 모델 정의
5 model = MarkovModel([( 'A', 'B'), ('B', 'C'), ('C', 'D'), ('D', 'A')])
6 factor1 = DiscreteFactor(['A', 'B'], [2, 2], [30, 5, 1, 10], state_names={'A': [0,1], 'B': [0,1]})
7 factor2 = DiscreteFactor(['B', 'C'], [2, 2], [100, 1, 1, 100], state_names={'B': [0,1], 'C': [0,1]})
8 factor3 = DiscreteFactor(['C', 'D'], [2, 2], [1, 100, 100, 1], state_names={'C': [0,1], 'D': [0,1]})
9 factor4 = DiscreteFactor(['D', 'A'], [2, 2], [100, 1, 1, 100], state_names={'D': [0,1], 'A': [0,1]})
10 model.add_factors(factor1, factor2, factor3, factor4)
11 print('모델의 타당성: ', model.check_model())

```

모델의 타당성: True



```

1 import numpy as np
2 pf_value = model.get_partition_function()
3 print('\n분할 함수의 값: ', pf_value)
4
5 infer = VariableElimination(model) # 추론 객체 생성
6
7 phi_ABCD = infer.query(['A', 'B', 'C', 'D']) # 전체 분포 phi(A,B,C,D)
8 print('phi(A,B,C,D)')
9 print(phi_ABCD)
10 P_ABCD = phi_ABCD.values/pf_value # 확률 = (팩터의 곱)/(분할 함수의 값)
11 PABCD = np.reshape(P_ABCD, -1)
12 for val in PABCD: # 확률의 출력
13     print(val, '\n')
14
15 A_dist = infer.query(['A']) # A의 분포 phi(A)
16 print('phi(A)')
17 print(A_dist)
18 P_A = A_dist.values/np.sum(A_dist.values)
19 for val in P_A:
20     print(val, '\n')
21
22 AIB0C1_dist = infer.query(['A'], evidence={'B':0, 'C':1}) # phi(A|B=0,C=1)
23 print('phi(A|B=0,C=1)')
24 print(AIB0C1_dist)
25 P_AIB0C1 = AIB0C1_dist.values/np.sum(AIB0C1_dist.values)
26 for val in P_AIB0C1:
27     print(val, '\n')

```

분할 함수의 값: 7201840.0

| phi(A,B,C,D) | | | | |
|--------------|------|------|------|--------------|
| C | D | A | B | phi(C,D,A,B) |
| C(0) | D(0) | A(0) | B(0) | 300000.0000 |
| C(0) | D(0) | A(0) | B(1) | 500.0000 |
| C(0) | D(0) | A(1) | B(0) | 100.0000 |
| C(0) | D(0) | A(1) | B(1) | 10.0000 |
| C(0) | D(1) | A(0) | B(0) | 300000.0000 |
| C(0) | D(1) | A(0) | B(1) | 500.0000 |
| C(0) | D(1) | A(1) | B(0) | 1000000.0000 |
| C(0) | D(1) | A(1) | B(1) | 100000.0000 |
| C(1) | D(0) | A(0) | B(0) | 300000.0000 |
| C(1) | D(0) | A(0) | B(1) | 5000000.0000 |
| C(1) | D(0) | A(1) | B(0) | 100.0000 |
| C(1) | D(0) | A(1) | B(1) | 100000.0000 |
| C(1) | D(1) | A(0) | B(0) | 30.0000 |
| C(1) | D(1) | A(0) | B(1) | 500.0000 |
| C(1) | D(1) | A(1) | B(0) | 100.0000 |
| C(1) | D(1) | A(1) | B(1) | 100000.0000 |

| phi(A) | | |
|--------|--------------|---------------------|
| A | phi(A) | |
| A(0) | 5901530.0000 | 0.8194475300756473 |
| A(1) | 1300310.0000 | 0.18055246992435267 |

| phi(A B=0,C=1) | | |
|----------------|-------------|-----------------------|
| A | phi(A) | |
| A(0) | 300030.0000 | 0.9993338440528928 |
| A(1) | 200.0000 | 0.0006661559471072178 |

Quiz

❖ 확률 분포에 대한 설명으로 적합하지 않는 것을 선택하시오.

- ① 관심대상을 표현하는 확률변수들에 대한 결합확률 분포를 가지고 있으면 다양한 상황에 대한 확률적 추론을 할 수 있다.
- ② 결합확률 분포를 가지고 있으면 특정한 조건부 확률이나 일부 확률변수에 대한 결합확률 분포를 계산할 수 있다.
- ③ 확률분포를 사용하여 불확실한 사건이나 지식을 표현할 수 있다.
- ④ 확률변수들은 서로 독립적이기 때문에 어떤 확률변수로 다른 확률변수에 대한 정보를 유추하는 것은 불가능하다.

❖ 확률에 대한 설명으로 적합하지 않는 것을 선택하시오.

- ① 확률변수 A가 갖는 값이 확률변수 B가 갖는 값과 전혀 연관이 없을 때 이들 확률변수는 서로 독립이라고 한다.
- ② 모든 확률변수가 서로 독립이면, 결합확률 분포는 확률분포들의 곱으로 표현할 수 없다.
- ③ 특정 확률변수 C의 값이 주어지면 확률변수 A와 B가 서로 독립일 때, C가 주어질 때 A와 B는 조건부 독립이라고 한다.
- ④ 조건부 독립의 성질을 갖는 확률변수들이 있으면 결합확률 분포를 확률분포들의 곱으로 표현할 수 있다.

Quiz

❖ 확률 그래프 모델에 대한 설명으로 적합하지 않는 것을 선택하시오.

- ① 확률 그래프 모델은 그래프 구조를 이용하여 확률변수간의 연관관계를 표현하여 확률분포에 표현 및 추론을 용이하게 한다.
- ② 마르코프 랜덤 필드에서 팩터는 지수함수로 정의해야 한다.
- ③ 마르코프 랜덤 필드에서는 확률변수들의 값의 조합별로 서로 부합되는 정도를 나타내는 호응정도값을 부여하는 팩터를 결정하고, 이 팩터들의 곱을 사용하여 확률값을 결정한다.
- ④ 베이저안 망에서는 방향 그래프를 사용하여 조건부 독립의 관계를 표현한다.

❖ 다음 지식표현에 관련한 설명으로 적합하지 않는 것을 선택하시오.

- ① 일상 상황에 대한 문제 해결을 위해서는 상식에 대한 지식이 필수적이며, 상식을 일차 술어 논리 형태의 지식을 구축하여, 이러한 문제 해결은 비교적 쉽게 해결할 수 있다
- ② 많은 지식을 포함하고 있는 시스템에 현재 해결하려는 문제에 관련된 지식을 선택하는 과정에서 시간이 너무 오래 걸릴 수 있는 문제를 프레임 문제라고 한다.
- ③ 기호 표기를 실제 세계의 의미와 연결시키는 것을 심볼 그라운드링이라 한다.
- ④ 기호로 지식을 표현하는 컴퓨터는 심볼 그라운드링을 할 수 있는 능력이 아직은 없다.